Lab 14 Human versus AI Reasoning Audit

Course: Cognitive Science
Environment: Google Colab
Estimated time: 120-150 minutes

Learning objectives

- Build a standardized reasoning-item table.
- Compare human and AI answers using explicit scoring.
- Classify errors without claiming identical internal mechanisms.

Theory in brief

Behavioral comparison can reveal accuracy, consistency, and framing sensitivity. It cannot by itself show that a machine and a person use the same cognitive process.

Ethics and data handling

Use an anonymous participant code. This classroom activity is not a diagnostic test. A student may use the simulation path instead of providing personal behavioral data.

Pre-lab prediction

Write a directional prediction and one theoretical reason before running the experiment.

My prediction: คนกับ AI น่าจะได้คะแนนรวมใกล้กันในโจทย์ที่มีคำตอบชัด แต่ AI อาจพลาดโจทย์ที่ต้องระวัง base-rate หรือ conjunction เพราะมันไวต่อการเลือกคำมากกว่าเหตุผลเชิงความน่าจะเป็น

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path
RNG = np.random.default_rng(42)
print('Environment ready')
```

```
Environment ready
```

In [2]:
```
items = pd.DataFrame([
    {'id':1,'type':'base_rate','question':'A description matches a stereotyp
    {'id':2,'type':'framing','question':'Program A saves 200 of 600 people;
    {'id':3,'type':'logic','question':'All artists are creative. Some teache
    {'id':4,'type':'conjunction','question':'Can P(A and B) exceed P(A)?','k

# กรอกคำตอบ (human = ตัวเรา, ai = ทดลองถามโมเดลสองรอบ) พร้อมให้คะแนนด้วย key
items['human_answer'] = ['base rate', 'equivalent', 'yes', 'no']
items['ai_answer_run1'] = ['base rate', 'equivalent', 'yes', 'no']
items['ai_answer_run2'] = ['base rate', 'depends on values', 'yes', 'no']
def score(ans, key):
    return int(str(ans).strip().lower() == str(key).strip().lower())
items['human_score']   = [score(a,k) for a,k in zip(items.human_answer, item
items['ai_score_run1'] = [score(a,k) for a,k in zip(items.ai_answer_run1, it
items['ai_score_run2'] = [score(a,k) for a,k in zip(items.ai_answer_run2, it
items.to_csv('lab14_reasoning_audit.csv', index=False)
items
```

Out[2]:

	id	type	question	key	human_answer	ai_answer_run1	ai_an
0	1	base_rate	A description matches a stereotype, but 5 of 1...	base rate	base rate	base rate	
1	2	framing	Program A saves 200 of 600 people; Program B h...	equivalent	equivalent	equivalent	
2	3	logic	All artists are creative. Some teachers are ar...	yes	yes	yes	
3	4	conjunction	Can P(A and B) exceed P(A)?	no	no	no	

Data entry protocol

Answer each item yourself before asking an AI. Use the exact same prompt twice in fresh conversations if allowed. Record model name, visible version, date, prompt, and settings. Score with the key or an instructor-approved rubric.

In [3]:
```
# After filling the CSV, upload it in Colab or edit the table above.
# Example analysis functions:
```

```python
def summarize_audit(df):
 out={}
 for c in ['human_score','ai_score_run1','ai_score_run2']:
  if c in df and df[c].notna().any(): out[c]=df[c].mean()
 if {'ai_answer_run1','ai_answer_run2'}<=set(df): out['ai_repeat_agreement']
 return out
print(summarize_audit(items))
```

```
{'human_score': np.float64(1.0), 'ai_score_run1': np.float64(1.0), 'ai_score
_run2': np.float64(0.75), 'ai_repeat_agreement': np.float64(0.75)}
```

Error taxonomy

Assign each wrong response to one defensible category: base-rate neglect, framing sensitivity, invalid inference, conjunction error, instruction failure, unsupported explanation, or other. Support the label with the response text.

Interpretation and submission

1. Main numerical result: human score = 1.00, AI score เฉลี่ยสองรอบ = 0.875 (run1 = 1.00, run2 = 0.75), agreement ระหว่างสองรอบของ AI = 0.75

2. Does it support the prediction: สนับสนุนบางส่วน คนกับ AI ทำโจทย์ชัดๆ ได้เท่ากัน แต่ AI ตอบไม่นิ่งในข้อ framing (รอบสองเปลี่ยนคำตอบ) ตรงกับที่คาดว่ามันไวต่อการเลือกคำ

3. Alternative explanation & design improvement: ทางเลือก: การที่ AI ตอบต่างสองรอบอาจมาจากความสุ่มของโมเดล ไม่ใช่ความเข้าใจที่ต่าง / ปรับปรุง: เพิ่มจำนวนข้อและถาม AI หลายรอบด้วย prompt เดียวกันเพื่อวัดความสม่ำเสมอให้เสถียร และให้คนมากกว่า 1 คนช่วย score ตาม rubric

4. Files: ดาวน์โหลด notebook นี้พร้อมไฟล์ CSV ที่ถูกสร้างขึ้นทุกไฟล์เพื่อส่ง

> หมายเหตุ: error ที่พบเป็นชนิด framing sensitivity (AI รอบสองไม่ยืนยันว่า A/B สมมูลกัน)

AI use declaration

- Tool/version: Claude (Anthropic)
- Purpose of use: ช่วยเขียนโค้ดส่วน simulation และการวิเคราะห์ และช่วยเรียบเรียงคำอธิบายผล
- Verification performed: รันโค้ดซ้ำจนไม่มี error และตรวจว่าตัวเลข/กราฟที่ได้สมเหตุสมผลตามทฤษฎีก่อนนำไปใช้