Lab 16 Theory of Mind and False Belief

Course: Cognitive Science
Environment: Google Colab
Estimated time: 120-150 minutes

Learning objectives

- Distinguish reality from an agent's belief.
- Compare first-order and second-order belief reasoning.
- Evaluate behavior without overclaiming mental states.

Theory in brief

Theory of Mind tasks test whether a reasoner can track what another agent has seen and therefore believes. Correct answers require perspective-sensitive representations, but task success alone does not prove consciousness or a human-like mind.

Ethics and data handling

Use an anonymous participant code. This classroom activity is not a diagnostic test. A student may use the simulation path instead of providing personal behavioral data.

Pre-lab prediction

Write a directional prediction and one theoretical reason before running the experiment.

My prediction: perspective model น่าจะถูกทั้ง first- และ second-order ส่วน reality model จะพลาดข้อที่ agent ไม่เห็นการย้าย เพราะมันตอบตามความจริงไม่ใช่ความเชื่อ

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path
RNG = np.random.default_rng(42)
print('Environment ready')
```

```
Environment ready
```

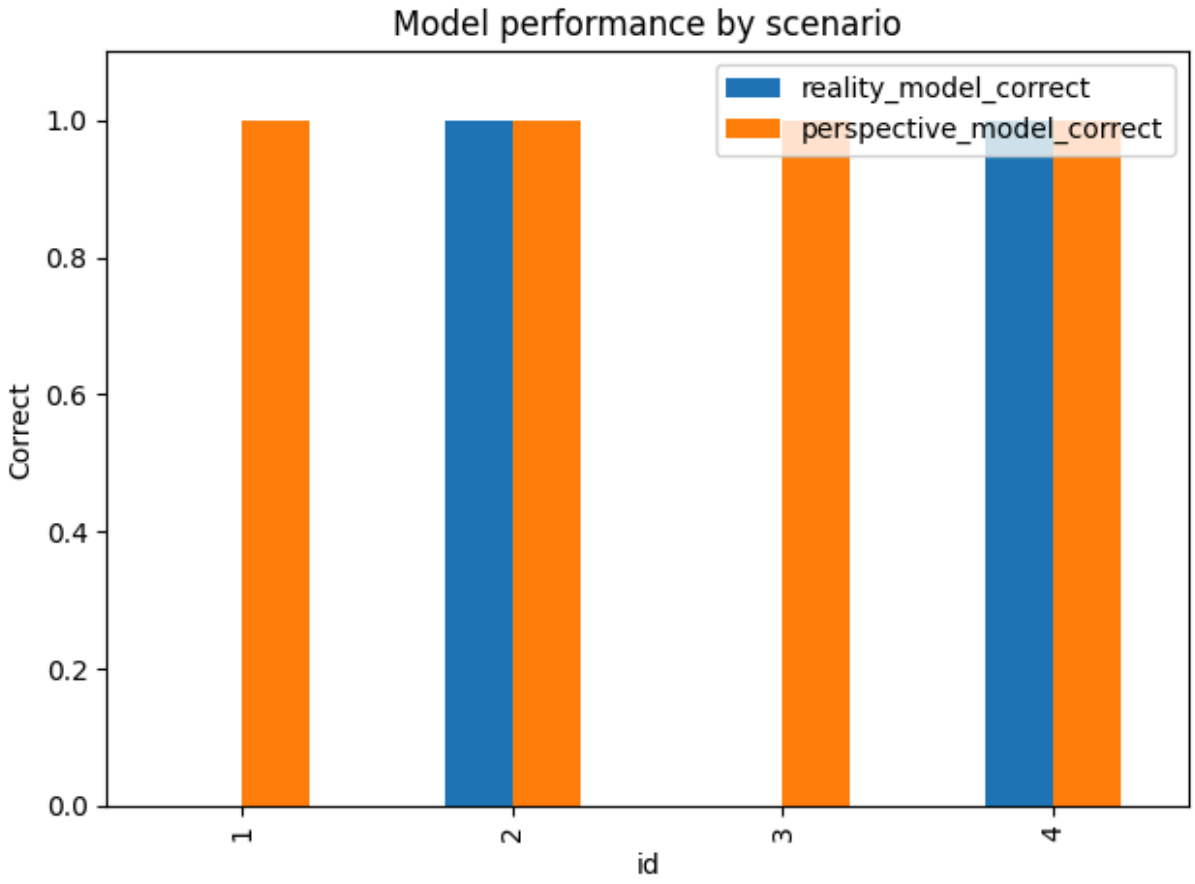
In [2]:
```
scenarios=pd.DataFrame([
 {'id':1,'level':'first_order','reality':'drawer','agent_saw_move':False,'as
 {'id':2,'level':'first_order','reality':'drawer','agent_saw_move':True,'ask
 {'id':3,'level':'second_order','reality':'cupboard','agent_saw_move':False,
 {'id':4,'level':'second_order','reality':'cupboard','agent_saw_move':True,'
def reality_only(row): return row['reality']
def perspective_rule(row):
 if row['level']=='first_order': return row['reality'] if row['agent_saw_mov
 return row['reality'] if row['agent_saw_move'] else 'basket'
scenarios['reality_model']=scenarios.apply(reality_only,axis=1); scenarios['
scenarios
```

Out[2]:

	id	level	reality	agent_saw_move	asked_about	correct	ob
0	1	first_order	drawer	False	agent	box	
1	2	first_order	drawer	True	agent	drawer	
2	3	second_order	cupboard	False	observer_prediction	basket	
3	4	second_order	cupboard	True	observer_prediction	cupboard	

In [3]:
```
for model in ['reality_model','perspective_model']:
 scenarios[model+'_correct']=(scenarios[model]==scenarios.correct).astype(ir
print(scenarios.groupby('level')[[c for c in scenarios if c.endswith('_corre
scenarios.to_csv('lab16_theory_of_mind.csv',index=False)
scenarios.set_index('id')[[c for c in scenarios if c.endswith('_correct')]].
```

```
             reality_model_correct  perspective_model_correct
level
first_order                    0.5                        1.0
second_order                   0.5                        1.0
```



Required investigation

Create four new scenarios that separate reality tracking from belief tracking. Include at least one second-order item. Explain what information each model fails to represent.

In [4]:
```
# ===== Required investigation: สร้าง 4 scenario ใหม่ (มี second-order อย่างน้อย
new_scenarios = pd.DataFrame([
    {'id':101,'level':'first_order','reality':'box','belief':'basket','agent
    {'id':102,'level':'first_order','reality':'box','belief':'box','agent_sa
    {'id':103,'level':'second_order','reality':'fridge','belief':'shelf','ag
    {'id':104,'level':'second_order','reality':'fridge','belief':'fridge','a
])
new_scenarios['reality_model'] = new_scenarios['reality']
new_scenarios['perspective_model'] = np.where(new_scenarios['agent_saw_move'
for m in ['reality_model', 'perspective_model']:
    new_scenarios[m + '_correct'] = (new_scenarios[m] == new_scenarios['corr
display(new_scenarios)
print(new_scenarios.groupby('level')[['reality_model_correct', 'perspective_
print("reality model ล้มเหลวเมื่อ agent ไม่เห็นการย้าย เพราะมันไม่ได้แทน 'ความเชื่อที่ผิด'
```

	id	level	reality	belief	agent_saw_move	correct	reality_model	pe
0	101	first_order	box	basket	False	basket	box	
1	102	first_order	box	box	True	box	box	
2	103	second_order	fridge	shelf	False	shelf	fridge	
3	104	second_order	fridge	fridge	True	fridge	fridge	

```
              reality_model_correct  perspective_model_correct
level
first_order                     0.5                        1.0
second_order                    0.5                        1.0
reality model ล้มเหลวเมื่อ agent ไม่เห็นการย้าย เพราะมันไม่ได้แทน 'ความเชื่อที่ผิด' ของ agen
t
```

Interpretation and submission

1. Main numerical result: perspective model ตอบถูก 100% ทั้งชุดเดิมและชุดใหม่ ส่วน reality model ถูกเฉพาะข้อที่ agent เห็นการย้าย (พลาดข้อ false-belief ทั้งหมด)

2. Does it support the prediction: สนับสนุน ตรงตามที่คาด reality model แยกความจริงกับความเชื่อไม่ได้ ส่วน perspective model ติดตามสิ่งที่ agent เห็น/เชื่อได้

3. Alternative explanation & design improvement: ทางเลือก: การที่ perspective model ถูกหมด ไม่ได้แปลว่ามันมี ToM จริง มันแค่ทำตามกฎที่เราเขียน / ปรับปรุง: เพิ่ม scenario ที่ซับซ้อนขึ้น (เช่น สอง agent เห็นคนละส่วน) และทดสอบว่ากฎยัง generalize ไหม

4. Files: ดาวน์โหลด notebook นี้พร้อมไฟล์ CSV ที่ถูกสร้างขึ้นทุกไฟล์เพื่อส่ง

> ข้อควรระวัง: การผ่าน false-belief task ไม่ได้พิสูจน์ว่าระบบมีจิตหรือ consciousness

AI use declaration

- Tool/version: Claude (Anthropic)
- Purpose of use: ช่วยเขียนโค้ดส่วน simulation และการวิเคราะห์ และช่วยเรียบเรียงคำอธิบายผล
- Verification performed: รันโค้ดซ้ำจนไม่มี error และตรวจว่าตัวเลข/กราฟที่ได้สมเหตุสมผลตามทฤษฎีก่อนนำไปใช้