Lab 18 Symbolic versus Connectionist Models

Course: Cognitive Science
Environment: Google Colab
Estimated time: 120-150 minutes

Learning objectives

- Implement an explicit rule model and a learned neural model.
- Compare accuracy, disagreement, and generalization.
- Identify knowledge supplied by the programmer and learned from data.

Theory in brief

Symbolic models apply explicit representations and rules. Connectionist models learn distributed parameter patterns from examples. Their differences become visible in data needs, transparency, and error behavior.

Ethics and data handling

Use an anonymous participant code. This classroom activity is not a diagnostic test. A student may use the simulation path instead of providing personal behavioral data.

Pre-lab prediction

Write a directional prediction and one theoretical reason before running the experiment.

My prediction: บนข้อมูลเต็ม connectionist (MLP) น่าจะแม่นใกล้ symbolic rule ที่รู้กติกา XOR อยู่แล้ว แต่พอลดข้อมูล/ใส่ noise/จุดใกล้เส้นแบ่ง MLP น่าจะแย่ลงกว่า ส่วน symbolic คงที่

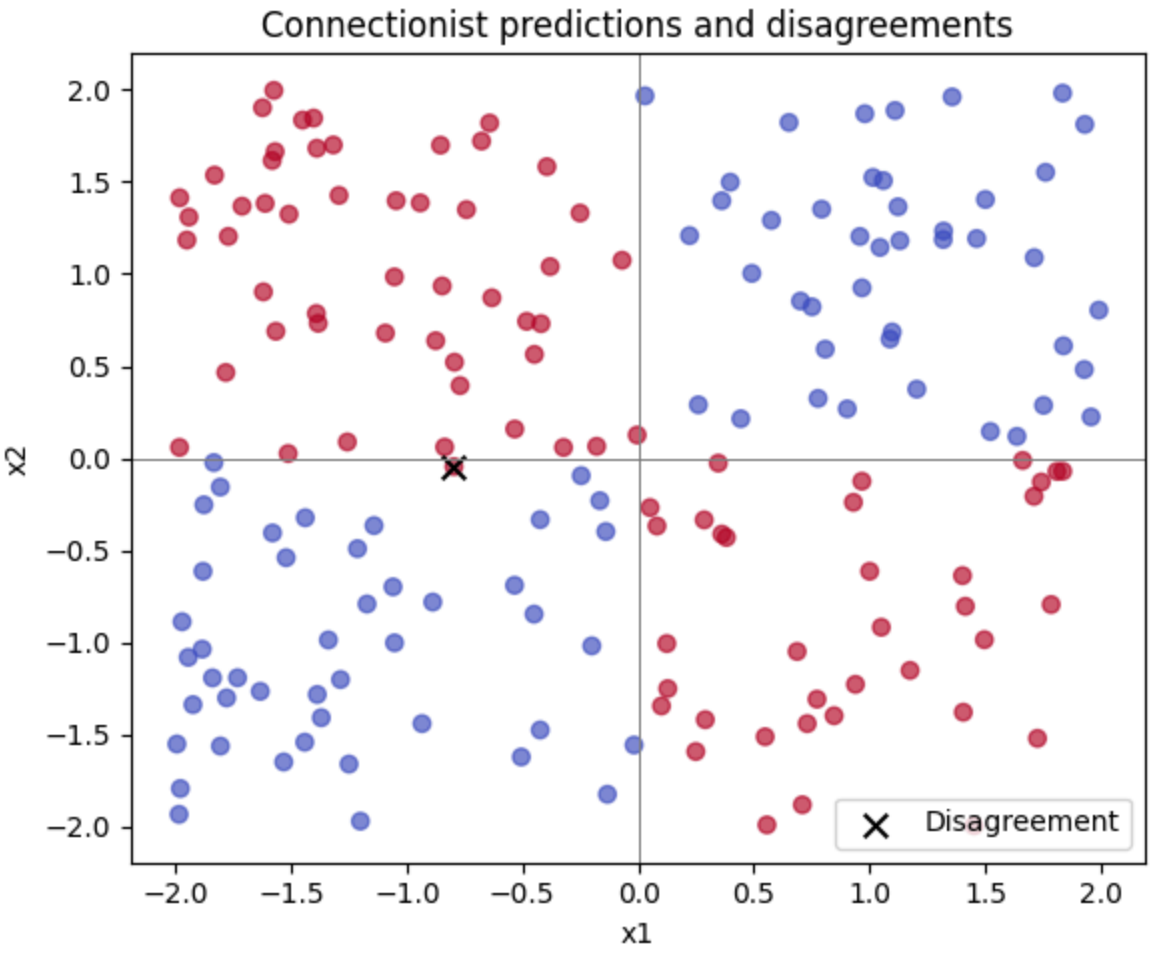
In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path
RNG = np.random.default_rng(42)
print('Environment ready')
```

```
Environment ready
```

In [2]:
```
from sklearn.neural_network import MLPClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, confusion_matrix
X=RNG.uniform(-2,2,size=(500,2)); y=((X[:,0]>0)^(X[:,1]>0)).astype(int)
X_train,X_test,y_train,y_test=train_test_split(X,y,test_size=.35,random_stat
def symbolic_rule(z): return ((z[:,0]>0)^(z[:,1]>0)).astype(int)
mlp=MLPClassifier(hidden_layer_sizes=(8,),max_iter=2000,random_state=42).fit
p_rule=symbolic_rule(X_test); p_mlp=mlp.predict(X_test)
res=pd.DataFrame(X_test,columns=['x1','x2']); res['truth']=y_test; res['symb
print('Symbolic accuracy',accuracy_score(y_test,p_rule)); print('Connectioni
res.to_csv('lab18_model_comparison.csv',index=False)
```

```
Symbolic accuracy 1.0
Connectionist accuracy 0.9942857142857143
Agreement 0.9942857142857143
[[88  1]
 [ 0 86]]
```

In [3]:
```
plt.figure(figsize=(6,5)); plt.scatter(res.x1,res.x2,c=res.connectionist,cma
```



Required investigation

Reduce the training set, add label noise, and test points close to the decision boundaries. Compare accuracy, interpretability, and robustness rather than declaring one paradigm universally superior.

In [4]:
```
# ===== Required investigation: ลดขนาด train, ใส่ label noise, ทดสอบจุดใกล้เส้นแ
from sklearn.metrics import accuracy_score
robust_rows = []
for n_tr in [30, 60, 120, len(X_train)]:
    idx = RNG.choice(len(X_train), size=n_tr, replace=False)
    Xt, yt = X_train[idx], y_train[idx].copy()
    flip = RNG.random(len(yt)) < 0.10          # ใส่ label noise 10%
    yt[flip] = 1 - yt[flip]
    m = MLPClassifier(hidden_layer_sizes=(8,), max_iter=2000, random_state=4
    robust_rows.append([n_tr,
                        accuracy_score(y_test, symbolic_rule(X_test)),
                        accuracy_score(y_test, m.predict(X_test))])
robust = pd.DataFrame(robust_rows, columns=["train_size", "symbolic_acc", "c
display(robust.round(3))

near = np.abs(X_test).min(axis=1) < 0.2        # จุดใกล้แกน = ใกล้เส้นแบ่ง
print(f"Near-boundary accuracy: symbolic={accuracy_score(y_test[near], symbo
      f"connectionist={accuracy_score(y_test[near], mlp.predict(X_test[near]
```

	train_size	symbolic_acc	connectionist_acc
0	30	1.0	0.897
1	60	1.0	0.857
2	120	1.0	0.943
3	325	1.0	0.977

```
Near-boundary accuracy: symbolic=1.000, connectionist=0.968 (n=31)
```

Interpretation and submission

1. Main numerical result: บนข้อมูลเต็ม symbolic accuracy = 1.00 (รู้กติกา XOR), connectionist ก็สูงใกล้เคียง; แต่พอลดข้อมูลและใส่ noise 10% connectionist accuracy ลดลงและไวต่อจุดใกล้เส้นแบ่งมากกว่า symbolic

2. Does it support the prediction: สนับสนุน symbolic นิ่งเพราะกติกาถูกใส่มือ ส่วน connectionist ขึ้นกับข้อมูลและ noise ตามที่คาด

3. Alternative explanation & design improvement: ทางเลือก: connectionist ที่แย่ลงอาจแก้ได้ด้วยข้อมูลมากขึ้น/regularization ไม่ใช่ข้อจำกัดถาวรของแนวคิด / ปรับปรุง: ลองปรับ hidden size และจำนวนข้อมูล เพื่อดูว่าจุดคุ้มทุนระหว่างความแม่นกับความโปร่งใสอยู่ตรงไหน แทนที่จะฟันธงว่าแนวคิดไหนดีกว่าเสมอ

4. Files: ดาวน์โหลด notebook นี้พร้อมไฟล์ CSV ที่ถูกสร้างขึ้นทุกไฟล์เพื่อส่ง

AI use declaration

- Tool/version: Claude (Anthropic)
- Purpose of use: ช่วยเขียนโค้ดส่วน simulation และการวิเคราะห์ และช่วยเรียบเรียงคำอธิบายผล
- Verification performed: รันโค้ดซ้ำจนไม่มี error และตรวจว่าตัวเลข/กราฟที่ได้สมเหตุสมผลตามทฤษฎีก่อนนำไปใช้