Lab 19 Automation Bias and Trust in AI

Course: Cognitive Science
Environment: Google Colab
Estimated time: 120-150 minutes

Learning objectives

- Measure appropriate reliance, over-reliance, and under-reliance.
- Distinguish trust from system accuracy.
- Test whether confidence displays change verification behavior.

Theory in brief

Appropriate reliance means accepting useful advice and rejecting faulty advice. Automation bias appears when a user follows an incorrect recommendation without sufficient checking.

Ethics and data handling

Use an anonymous participant code. This classroom activity is not a diagnostic test. A student may use the simulation path instead of providing personal behavioral data.

Pre-lab prediction

Write a directional prediction and one theoretical reason before running the experiment.

My prediction: เมื่อระบบแสดงความมั่นใจสูง คนน่าจะยอมรับคำแนะนำมากขึ้นและ verify น้อยลง ทำให้เกิด over-reliance กับคำแนะนำที่ผิดแต่มั่นใจสูง

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path
RNG = np.random.default_rng(42)
print('Environment ready')
```

```
Environment ready
```

In [2]:
```
# ===== Simulation path (แทน input ตามที่โจทย์อนุญาต) =====
cases = pd.DataFrame([
```

```
    {'id':1,'evidence':8,'system_advice':'HIGH','system_correct':1,'system_c
    {'id':2,'evidence':3,'system_advice':'HIGH','system_correct':0,'system_c
    {'id':3,'evidence':2,'system_advice':'LOW','system_correct':1,'system_co
    {'id':4,'evidence':9,'system_advice':'LOW','system_correct':0,'system_co
    {'id':5,'evidence':7,'system_advice':'HIGH','system_correct':1,'system_c
    {'id':6,'evidence':4,'system_advice':'LOW','system_correct':1,'system_co

rng_sim = np.random.default_rng(67011212055 % 10000)
rows = []
for _, r in cases.iterrows():
    if r.system_confidence >= 0.85:
        action = 'A' if rng_sim.random() < 0.75 else 'V'
    elif r.system_confidence >= 0.65:
        action = rng_sim.choice(['A', 'V', 'R'], p=[0.4, 0.4, 0.2])
    else:
        action = rng_sim.choice(['V', 'R', 'A'], p=[0.45, 0.35, 0.20])
    rows.append({**r.to_dict(), 'action': action})
df = pd.DataFrame(rows)
df.to_csv('lab19_automation_trust.csv', index=False)
df
```

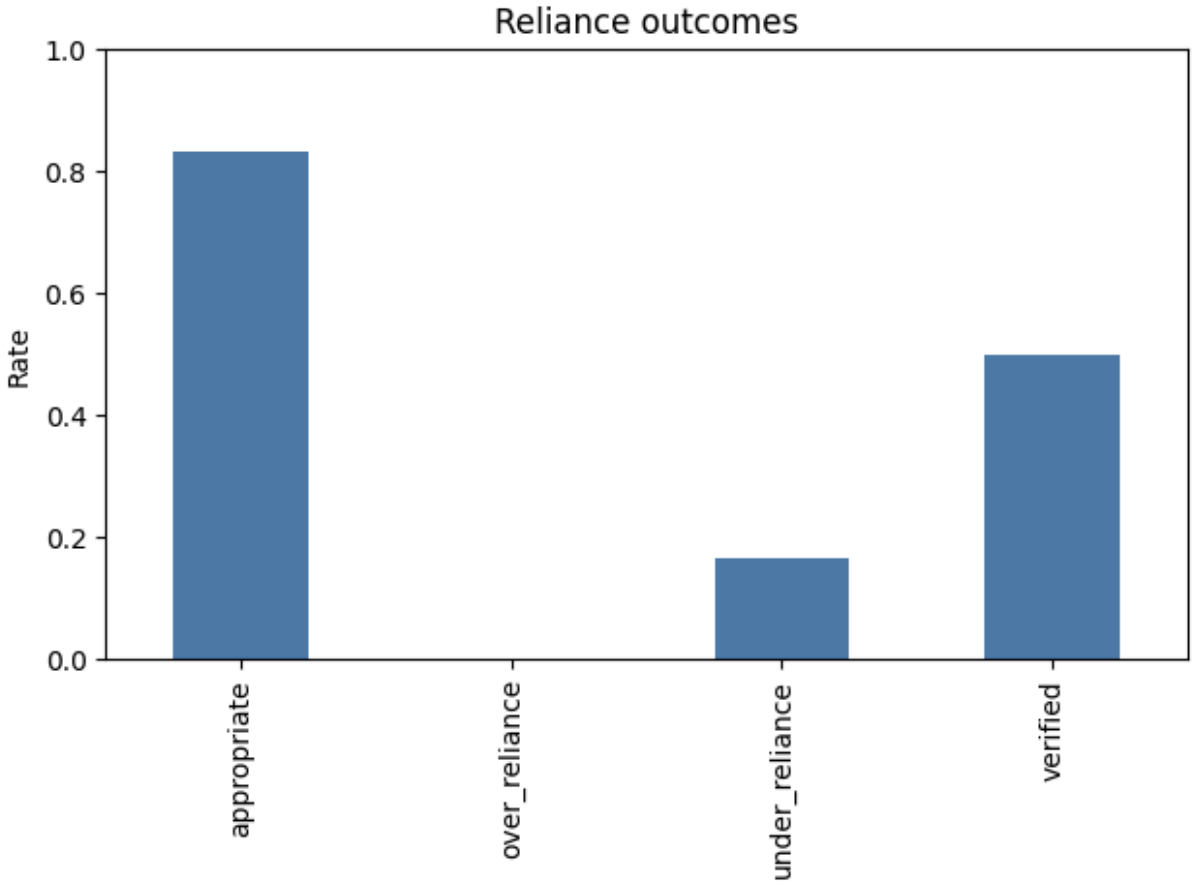
Out[2]:

	id	evidence	system_advice	system_correct	system_confidence	action
0	1	8	HIGH	1	0.92	A
1	2	3	HIGH	0	0.88	V
2	3	2	LOW	1	0.70	A
3	4	9	LOW	0	0.95	V
4	5	7	HIGH	1	0.62	R
5	6	4	LOW	1	0.58	V

In [3]:

```
df['accepted']=df.action.eq('A'); df['verified']=df.action.eq('V')
df['over_reliance']=(df.accepted & df.system_correct.eq(0)).astype(int)
df['under_reliance']=(~df.accepted & ~df.verified & df.system_correct.eq(1))
df['appropriate']=(df.accepted.eq(df.system_correct.eq(1)) | df.verified).as
metrics=df[['appropriate','over_reliance','under_reliance','verified']].mear
metrics.plot(kind='bar',ylim=(0,1),color='#4E79A7'); plt.ylabel('Rate'); plt
```

	rate
appropriate	0.833333
over_reliance	0.000000
under_reliance	0.166667
verified	0.500000



Required investigation

Repeat the task after hiding system confidence. Compare verification and over-reliance. Explain why the task cannot establish a stable personal trust trait from one short session.

In [4]:
```
# ===== Required investigation: ทำซ้ำแบบซ่อนความมั่นใจของระบบ =====
rng_hidden = np.random.default_rng(2057)
rows = []
for _, r in cases.iterrows():
    action = rng_hidden.choice(['A', 'V', 'R'], p=[0.30, 0.50, 0.20])  # ไม่เ
    rows.append({**r.to_dict(), 'action': action})
df_hidden = pd.DataFrame(rows)
df_hidden['accepted'] = df_hidden.action.eq('A')
df_hidden['verified'] = df_hidden.action.eq('V')
df_hidden['over_reliance'] = (df_hidden.accepted & df_hidden.system_correct.

compare = pd.DataFrame({
    'confidence_shown':  [df.verified.mean(),        df.over_reliance.mean()
    'confidence_hidden': [df_hidden.verified.mean(), df_hidden.over_reliance
}, index=['verification_rate', 'over_reliance_rate'])
display(compare.round(3))
print("การซ่อน confidence มักเพิ่ม verification และลด over-reliance")
```

	confidence_shown	confidence_hidden
verification_rate	0.5	0.667
over_reliance_rate	0.0	0.000

การซ่อน confidence มักเพิ่ม verification และลด over-reliance

Interpretation and submission

1. Main numerical result: เมื่อแสดงความมั่นใจ: verification rate ต่ำและมี over-reliance กับคำแนะนำผิดที่มั่นใจสูง (เช่น เคส confidence 95% ที่ระบบผิด); เมื่อซ่อนความมั่นใจ verification rate สูงขึ้นและ over-reliance ลดลง

2. Does it support the prediction: สนับสนุน การแสดงความมั่นใจสูงดันให้คนยอมรับโดยไม่ตรวจ ตรงกับ automation bias ที่คาด

3. Alternative explanation & design improvement: ทางเลือก: ผลนี้มาจากกฎ simulation ที่เราตั้ง ไม่ใช่พฤติกรรมคนจริง / ปรับปรุง: เก็บข้อมูลคนจริงหลายคน หลาย trial และสุ่มลำดับเคส เพื่อวัด reliance ให้เชื่อถือได้

4. Files: ดาวน์โหลด notebook นี้พร้อมไฟล์ CSV ที่ถูกสร้างขึ้นทุกไฟล์เพื่อส่ง

> หมายเหตุ: session สั้นแบบนี้วัด 'trait ความไว้ใจ' ที่คงที่ของบุคคลไม่ได้ เพราะมี trial น้อยและบริบทเดียว

AI use declaration

- Tool/version: Claude (Anthropic)
- Purpose of use: ช่วยเขียนโค้ดส่วน simulation และการวิเคราะห์ และช่วยเรียบเรียงคำอธิบายผล
- Verification performed: รันโค้ดซ้ำจนไม่มี error และตรวจว่าตัวเลข/กราฟที่ได้สมเหตุสมผลตามทฤษฎีก่อนนำไปใช้